ColdNet：面向冷启动、不平衡与零膨胀结果的处理效应估计

Sanskar Tewatia（应用科学家）

Mahmudur Rahman（应用科学家 II）

Dhruv Garg（应用科学经理）

中文翻译版

ColdNet：面向冷启动、不平衡与零膨胀结果的处理效应估计

Sanskar Tewatia
应用科学家
tsanskar@amazon.com

Mahmudur Rahman
应用科学家 II
mahmudxm@amazon.com

Dhruv Garg
应用科学经理
gargdhru@amazon.com

摘要

当以下三类挑战同时出现时，基于观察数据估计个体处理效应（Individual Treatment Effect，ITE）会变得不可靠：极端类别不平衡（处理率 0.4%）、结果稀疏（97.6% 为零）以及普遍存在的冷启动（99.2% 的画像不完整）。这些条件会破坏识别假设：倾向得分会向边界值坍缩，而对于历史特征稀疏的主体，结果预测也会恶化。我们提出 ColdNet，这是一种神经因果架构，包含三项创新：（1）按结果分层的集成学习，在保留结果异质性的同时，将有效不平衡从 1:256 降低到 1:2；（2）结合稀疏感知预处理的目标正则化，通过反事实校正强制学习平衡表征；（3）基于聚类的冷启动增强，通过保持局部性的分位数聚合，从相似训练样本迁移预测。在用于 3P 卖家推荐的生产级电商数据集上（153 万训练样本、59 万测试样本），ColdNet 在冷启动案例上实现了 27.6% 的 MAE 和 WAPE 改善，并将中位误差降低 82.8%；同时，半合成验证显示，在相同不平衡条件下，其处理效应估计优于 Double Machine Learning 13.9 倍。ColdNet 已部署在生产环境中，目前每周在美国和 3 个欧盟市场处理超过 40 亿次预测。

1 引言

用于个性化干预的生产机器学习系统，例如促销优惠、处理推荐和资源分配，都依赖准确的个体处理效应（ITE）估计，以便在大规模场景下驱动关键业务决策。然而，真实部署往往会遇到一组叠加的数据难题：低于 1% 的处理率造成极端类别不平衡；被零值主导的结果分布掩盖了真正会响应处理的主体；多数主体缺少可靠预测所需的历史特征。在我们处理 2.29 亿样本的生产级电商卖家推荐系统中，这些问题同时以大规模形式出现：0.3% 的处理率（1:256 不平衡）、97.6% 的零结果，以及 99.2% 的冷启动案例。在这些条件下，Double Machine Learning（DML）[4] 等经典计量经济学方法会出现灾难性失败，即倾向得分向边界值坍缩；而 DragonNet [25] 和 TARNet [24] 等最先进的神经因果模型在冷启动群组上会产生负的 R^2 值。我们提出 ColdNet，这是一种系统性应对上述每项挑战的神经因果架构。

挑战 1：极端类别不平衡。 0.3% 的处理率（1:256 不平衡）会导致倾向得分集中在接近零的位置，从而给正值性假设（positivity assumption）[8] 带来压力。关键在于，不同结果层中的不平衡程度不同：零结果主体的处理率接近零，而高绩效主体的采纳率更高，因此统一重采样无效。SMOTE [3] 等标准方法假设不平衡是同质的，当处理率在不同结果分箱之间差异较大时会失败。

挑战 2：结果稀疏。 当 97.6% 的结果为零时，损失函数会被大量零值主导，使模型无法区分真正无响应者（$\tau(x) \approx 0$）与稀疏观测（具有正向处理潜力但在控制条件下观测结果为零的主体）。这种混淆会使处理效应估计向零偏移，因为模型学到的是预测占主导地位的零类别，而不是捕捉异质性处理效应。

挑战 3：冷启动场景。 共计 99.2% 的主体具有不完整的历史特征画像，迫使模型在缺少训练信号的稀疏特征区域中进行外推。标准插补会消除“缺失本身”所携带的信息信号，而基于均值的兜底策略会忽略冷启动主体之间的结构相似性。推荐系统中已有的冷启动解决方案 [26] 会迁移预测，但不会迁移反事实结构。

ColdNet 使用有针对性的创新来应对每项挑战（见图 1）。我们的贡献如下：

- **按结果分层的集成学习**（第 2.3 节）：在保留结果异质性的同时，将有效类别不平衡从 1:256 降低到 1:2，并实现 0.926 的倾向 AUC 和 0.910 的安慰剂有效性。
- **结合稀疏感知预处理的目标正则化**（第 2.4 节）：通过反事实校正强制学习平衡表征，使其在相同不平衡条件下，处理效应估计效果比 DML 好 13.9 倍。
- **基于聚类的冷启动增强**（第 2.5 节）：通过保持局部性的分位数聚合，从相似训练样本迁移预测，在冷启动案例上实现 19.1% 的 MAE 改善和 82.8% 的中位误差降低。
- **大规模生产验证**（第 4 节）：在 153 万训练样本、99.2% 冷启动率的数据上验证，并已部署为每周处理数十亿次预测，证明神经因果模型可以同时实现科学严谨性与运营卓越性。

本文剩余部分组织如下：第 2 节形式化 CATE 估计问题，并介绍 ColdNet 架构，详细说明每个组件如何应对上述挑战；第 3 节和第 4 节在生产数据和半合成基准上评估 ColdNet；最后以相关工作和讨论作为结论。

2 方法

我们首先形式化 CATE 估计问题，然后介绍 ColdNet 的架构，并说明每个组件如何应对前述挑战。

问题形式化。 我们估计条件平均处理效应（Conditional Average Treatment Effect，CATE）：

$$\tau(x) = E\left[Y(1) - Y(0) \mid X = x\right]$$

即在协变量为 x 的主体中，处理与控制两种潜在结果之间的期望差异。有效估计需要三个识别假设 [12]。**无混杂性**：$Y(0), Y(1) \perp T \mid X$，即在给定协变量后，处理分配与潜在结果独立。**正值性**：$0 < P(T = 1 \mid X) < 1$，即每个主体都有非零概率接受任一处理状态。一**致性**：$Y = T \cdot Y(1) + (1 - T) \cdot Y(0)$，即观测结果等于其实际接受处理状态下的潜在结果。我们的原始数据集包含 2.29 亿样本和 161 个特征，表现为 0.39% 的处理率（1:256 不平衡）、99.25% 的冷启动案例和 97.6% 的零结果。这些条件在实践中会严重考验上述假设。

神经因果模型架构。 ColdNet 构建于 DragonNet [25] 之上。DragonNet 学习共享表征 $\Phi(X)$，并将其输入到三个预测头（图 1A）：用于控制和处理潜在结果的结果头 $\mu_0(X)$ 与 $\mu_1(X)$，以及用于处理概率的倾向头 $\pi(X)$。共享表征捕捉同时影响处理选择和结果的混杂因子，使模型能够通过寻找作出不同处理选择的相似样本来学习反事实。训练目标为：

$$L = \lambda_{out} \cdot MSE\left(Y, T \cdot \mu_1 + (1 - T) \cdot \mu_0\right) + \alpha \cdot BCE(T, \pi) + \beta \cdot MSE\left(Y, \hat{Y} + \epsilon \cdot cc\right)$$

第一项仅在观测结果上训练结果预测；第二项学习倾向得分以捕捉选择偏差；第三项为目标正则化，其中 $cc = T/\pi(X) - (1-T)/(1-\pi(X))$，在损失中实现逆倾向加权，强制学习平衡表征，从而捕捉因果关系而非关联关系。附录 A 提供了更详细的直觉解释。

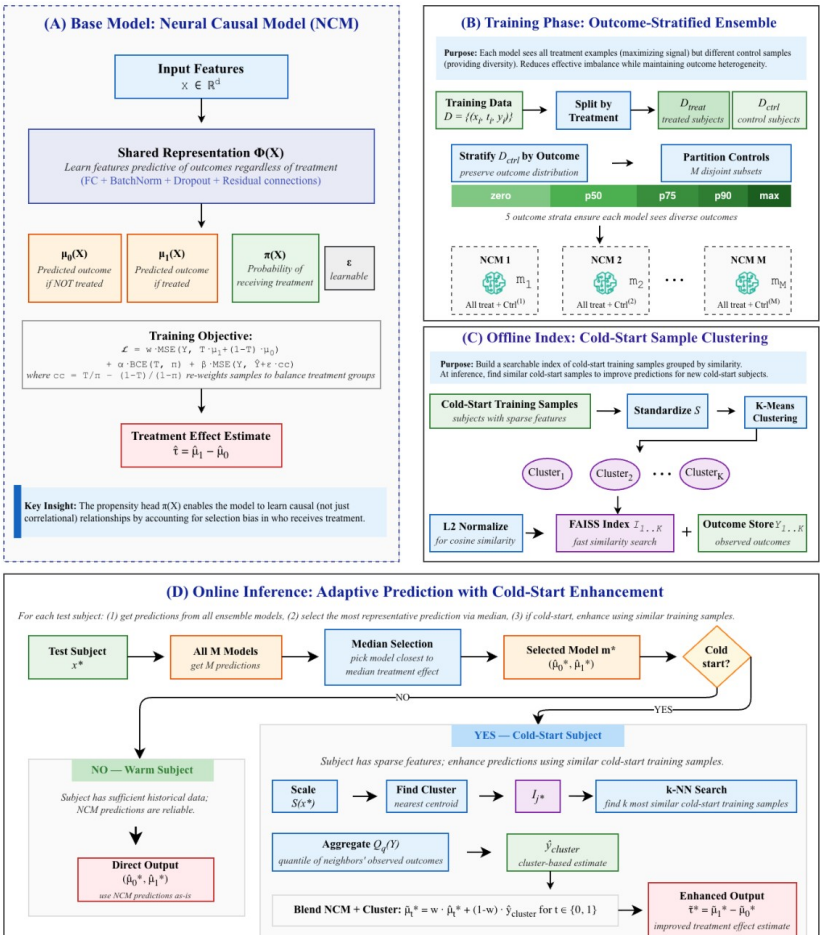


图 1：ColdNet 用于反事实预测中基于聚类的冷启动增强架构。为保留原图结构与视觉细节，图内英文标签按原 PDF 保留。

图 1：用于反事实预测中基于聚类的冷启动增强的 ColdNet 架构。（A）基础神经因果模型（NCM）扩展 DragonNet，具有三个预测头：控制结果 $\mu_0(X)$、处理结果 $\mu_1(X)$ 和倾向 $\pi(X)$。这些预测头运行在通过全连接层、批归一化、dropout 和残差连接学习到的共享表征 $\Phi(X)$ 上。训练目标结合了结果预测（加权 MSE）、处理预测（BCE）和通过反事实校正项 $cc = T/\pi(X) - (1-T)/(1-\pi(X))$ 实现的目标正则化，该项对样本重新加权，以平衡处理组并支持因果推断。（B）训练阶段通过按结果分层的集成学习来处理极端类别不平衡：训练数据按处理分配拆分为 D_{treat} 和 D_{ctrl}；控制主体按 5 个结果分箱（zero、p50、p75、p90、max）分层；随后划分为 M 个互不重叠的子集。每个集成成员 m_m 在所有处理主体加一个控制分区上训练，从而最大化处理信号并提供集成多样性。（C）离线冷启动索引构建：对冷启动训练样本进行标准化，通过 K-Means 聚成 K 组，进行 L2 归一化，并使用 FAISS 建立索引以支持高效近邻搜索，同时为每个聚类存储观测结果 $Y_{1..K}$。（D）在线推断：所有 M 个模型评估测试主体 $x^{¿}$；选择最接近中位处理效应 $\hat{\tau}_{median}$ 的模型；暖启动主体直接接收 NCM 输出，而冷启动主体通过检索 k 个相似训练样本并进行混合来增强：$\tilde{\mu}_t^{¿} = w \cdot \hat{\mu}_t^{¿} + (1-w) \cdot \hat{y}_{cluster}$，其中 $t \in \{0,1\}$。

应对挑战 1：极端类别不平衡。 我们的数据集（第 3 节）呈现 1:256 的类别不平衡，并且不同结果层中的处理率具有异质性，因此统一重采样无效。我们通过按结果分层的集成学习来解决这一问题：将控制组通过 5 个结果分箱（zero、p50、p75、p90、max）进行分层采样，并划分为 M 个互不重叠的子集。每个 M 模型都接收完整的处理组以及一个控

制子集（图 1B），从而在保留结果异质性的同时，将不平衡从 1:256 降至 1:2。推断时，所有 M 个模型都会评估每个测试样本；我们通过 $m^{¿} = arg\,min_m \left|\hat{\tau}_m - \hat{\tau}_{median}\right)$ 选择最接近集成中位数的模型，并使用 $m^{¿}$ 的全部输出（μ_0, μ_1, π）以保持一致性。中位数选择对异常模型具有鲁棒性。

应对挑战 2：结果稀疏。 在 97.6% 结果为零的情况下，模型无法区分真正无响应者（$\tau(X) \approx 0$）与稀疏观测（具有正处理潜力但观测控制结果为零），而真正无响应者应得到 $\hat{\tau} \approx 0$。我们通过目标正则化和稀疏感知预处理解决此问题。$c\,c$ 项会提升信息量更高样本的权重；预处理则包含：在保留零值的情况下进行 MinMax 缩放至 $[0, 2.5)$；在第 99.5 百分位进行 winsorization 截尾，以防异常值主导 MSE 损失；以及分层批采样，对非零结果过采样，以确保每个批次约含 30% 的正例（原始数据中仅 2.4%）。完整细节见附录 B。

NCM 架构选择。 我们消融了四种架构（完整结果见附录 C 的表 5）：TARNet（仅结果头）、不含目标正则化（TR）的 DragonNet、含 TR 的 DragonNet，以及 DragonNet+GMS（辅助分类器）。关键洞察是，仅靠倾向建模并不充分，目标正则化是必要的。加入倾向头会改善处理预测（AUC：0.500→0.919），但如果没有 TR，模型学习的是关联关系而不是因果关系。安慰剂测试清楚地揭示了这一点：随机为控制样本分配伪处理并检查是否存在虚假效应；不含 TR 的 DragonNet 因果有效性最差（p-value = 0.085），而含 TR 的 DragonNet 最好（p-value = 0.910）。基于这些结果，我们选择含 TR 的 DragonNet，因为其倾向校准最好（AUC = 0.926）、因果有效性最强（安慰剂 p-value = 0.910），且中位误差最低（28.03 美元，相比 TARNet 的 38.50 美元）。

半合成验证：NCM vs. DML。 半合成验证通过在真实协变量上生成合成处理效应来提供真实 CATE [9, 7]。我们使用生产特征（900 万样本、72 个特征）和三种数据生成过程（DGP）：Sine、Linear 和 Interaction。训练数据处理率为 7.8%，测试数据平衡为 30%。表 1 在 Sine DGP 上比较了三种方法：Mean Baseline（预测常数 $\hat{\tau} = \acute{\tau}_{train}$）、DML（XGBoost T-Learner，5 折交叉拟合）和 NCM（带目标正则化的 DragonNet）。我们报告七项指标，覆盖个体层准确性（$\sqrt{PEHE}$、CATE R^2、CATE Correlation）、总体层估计（ATE Relative Bias、ATT Bias）以及分布尾部稳定性（QTE P10/P90 Bias）。

表 1：半合成验证（Sine DGP）：在 7.8% 处理率下比较 NCM 与 DML。↓ 越低越好，↑ 越高越好。Linear 和 Interaction DGP 结果见附录 D。

指标	Mean	DML	NCM	NCM vs DML
$\sqrt{PEHE}$ ↓	0.118	1.220	0.088	好 13.9×
CATE R^2 ↑	-0.006	-105.8	0.442	+106.2 pts
CATE Correlation ↑	0.000	0.309	0.668	好 2.2×
ATE Rel. Bias % ↓	-5.5%	-17.7%	+4.3%	小 4.1×
ATT Bias ↓	-0.024	-0.101	+0.008	小 12.6×
QTE P10 Bias ↓	+0.138	-0.198	+0.052	小 3.8×
QTE P90 Bias ↓	-0.161	+0.220	-0.039	小 5.6×

DML 在类别不平衡下出现灾难性失败：CATE R^2 = -105.8 表示预测效果比常数均值还差；ATT Bias 为 -0.101，代表对已处理人群处理效应的严重低估。NCM 在所有指标上都实现了稳健估计：$\sqrt{PEHE}$ 好 13.9 倍，CATE R^2 为正（0.442），尾部估计稳定（QTE 偏差小 3.8-5.6 倍）。这证明 NCM 在不平衡条件下的优势能够转化为准确的处理效应估计，而不仅仅是更好的结果预测。

应对挑战 3：冷启动场景。 我们为 97.9% 历史特征不完整的样本引入了基于 K-Means 聚类的冷启动增强。若六个历史活动特征中任一特征为零（包括 offer 级和 ASIN 级、90/365 天窗口的指标），则样本被定义为冷启动；该定义覆盖 97.9% 的原始样本和 58.6% 的平衡训练样本（完整定义见附录 H）。关键假设是：非历史特征相似的冷启动样本倾向于表现出相似结果。该算法分三阶段运行（图 1C、D；伪代码见附录 G）。第一，在按结果分层的集成训练（第 2.3 节）中产生 M 个 NCM 模型。第二，在离线索引构建阶段，对冷启动训练样本进行标准化，通过 K-Means 聚为 K 组，L2 归一化，并使用 FAISS [13] 建立索引，同时按聚类存储观测结果。第三，在线推断时，所有 M 个模型评估测

试样本 $x^{¿}$，中位数选择得到 $m^{¿}$；暖启动样本直接使用 NCM 输出，而冷启动样本则通过寻找最近聚类、使用 FAISS 检索 k 个相似训练样本、用分位数 Q_q 聚合其结果，并与 NCM 预测混合来增强。我们使用第 45 百分位而非均值进行聚合，因为冷启动结果是零膨胀的，均值聚合会过度加权少数高值异常点，而我们的超参数分析确认其会使 MAE 恶化 +1.3%。关键的是，我们通过 $\tilde{\mu}_t^{¿} = w \cdot \hat{\mu}_t^{¿} + (1-w) \cdot \hat{y}_{cluster}$ 同时混合两个潜在结果头（$t \in \{0,1\}$），从而保留反事实结构 $\tilde{\tau} = \tilde{\mu}_1 - \tilde{\mu}_0$。最终超参数为：$K = 20$ 个聚类、$k = 10$ 个邻居、$w = 0.1$ 的 NCM 权重、$q = 0.45$（第 45 百分位）。

3 实验

数据集。 我们在两个互补数据集上评估：用于真实世界验证的生产级电商数据，以及用于真实 CATE 评估的半合成数据。

生产数据集。 原始数据集包含来自某大型电商平台的 2.29 亿个卖家-offer 样本，具有 161 个特征，覆盖商品属性（类目、价格、品牌）、卖家特征（经营年限、评分、库存）以及历史活动指标（90/365 天窗口的销售额、转化率）。表 2 总结了处理后的数据集。0.39% 处理率、99.25% 冷启动、97.6% 零结果这类极端条件，使其成为因果推断方法的高难度基准。

表 2：数据集摘要，展示原始生产数据以及用于训练和评估的处理后切分。

数据集	样本数	处理 %	冷启动 %	用途
Raw Production	229M	0.39	99.25	源数据
Balanced Train（每个子集 m）	1.53M	45.87	58.62	NCM/ColdNet 训练
Balanced Test	590K	24.9	40.67	评估
Semi-Synthetic Train	80K	7.8	-	DML 训练（不平衡）
Semi-Synthetic Test	20K	30	-	真实 CATE 评估

半合成数据集。 按照 [9, 7]，我们在真实协变量上生成合成处理效应，以获得真实 CATE。我们使用 900 万生产样本和 72 个数值特征，并应用三种数据生成过程（DGP）：Sine（$\tau(x) = \sin(\omega^\top x)$）、Linear（$\tau(x) = \beta^\top x$）以及 Interaction（$\tau(x) = x_1 \cdot x_2$）。这使我们能够直接评估处理效应估计质量，而不只是评估结果预测。

模型比较。 我们比较了神经因果模型、计量经济学方法和消融变体。基线包括 Mean Baseline（对所有样本预测常数 $\hat{\tau} = \acute{\tau}_{train}$）、DML [4]（XGBoost T-Learner，5 折交叉拟合，标准计量经济学方法）、TARNet [24]（无倾向建模的双头架构）、不含 TR 的 DragonNet（加入倾向头但没有目标正则化）以及标准 DragonNet [25]（加入倾向头和目标正则化）。我们提出的方法包括 NCM（带目标正则化和按结果分层集成的 DragonNet）以及 ColdNet（NCM 加 K-Means 冷启动增强，即完整方法）。

评估指标。 我们按冷启动状态分层结果：40.7% 为冷启动样本，59.3% 为暖启动样本，这一点很重要，因为 K-Means 增强仅对冷启动样本生效。我们评估四项互补指标：i）MAE：平均绝对误差，主要准确性指标，包含异常值影响；ii）Median Error：反映“平均”样本的表现；iii）Median Bias：系统性高估/低估，用于检测校准问题；iv）WAPE：加权绝对百分比误差，支持跨尺度比较。对于半合成验证，我们还报告 $\sqrt{PEHE}$（异质性效应估计精度的平方根）和 CATE R^2，这些指标需要真实个体处理效应。完整指标定义见附录 E。

表 3：在 590K 测试样本上的主要结果，比较 Baseline、NCM 和 ColdNet。Δ1：Baseline→ColdNet 改善；Δ2：NCM→ColdNet 改善（K-Means 贡献）。所有误差值单位为美元。

群组	指标	DragonNet（Baseline）	NCM	ColdNet	Δ1	Δ2
Cold-Start（240K）	MAE (USD)	115.36	103.17	83.47	-27.6%	-19.1%
Cold-Start（240K）	Median Error (USD)	41.84	21.14	3.64	-91.3%	-82.8%
Cold-Start（240K）	Median Bias (USD)	40.27	12.88	1.02	-97.5%	-92.1%
Cold-Start（240K）	WAPE	0.912	0.815	0.660	-27.6%	-19.0%
Warm（350K）	MAE (USD)	376.79	306.00	306.00	-18.8%	0.0%
Warm（350K）	Median Error (USD)	52.31	38.50	38.50	-26.4%	0.0%
Warm（350K）	Median Bias (USD)	28.14	15.22	15.22	-45.9%	0.0%
Warm（350K）	WAPE	0.824	0.669	0.669	-18.8%	0.0%
Overall（590K）	MAE (USD)	270.46	223.40	215.38	-20.4%	-3.6%
Overall（590K）	WAPE	0.856	0.707	0.665	-22.3%	-5.9%

实现细节。 NCM 架构包含一个共享表征网络，由三层全连接层（512→256→128 单元）组成，使用批归一化、ReLU 激活和 dropout（比例 0.236）。结果头（μ_0 和 μ_1）各包含两层（64→1），倾向头使用相同结构并以 sigmoid 输出。我们使用 Adam 优化器训练，学习率为 3.98×10^{-4}，批大小为 256，最多 50 个 epoch，并使用 patience 为 15 的早停策略。对于 ColdNet 增强，我们在标准化特征上将冷启动训练样本聚成 $K = 20$ 组，然后使用 L2 归一化向量构建 FAISS 索引，以便进行高效内积搜索。推断时，检索 $k = 10$ 个最近邻，使用第 45 百分位（$q = 0.45$）聚合其结果，并以权重 $w = 0.1$ 与 NCM 预测混合。我们进行了 18 组配置的超参数调优，完整结果见附录 F。

4 结果

表 3 给出了在 590K 测试样本上的综合评估结果，并按冷启动状态分层。我们报告四项指标：MAE（平均绝对误差，主要准确性指标）、Median Error（典型预测质量）、Median Bias（系统性高估/低估）和 WAPE（用于跨尺度比较的加权绝对百分比误差）。表中展示了三种方法：Baseline（标准 DragonNet）、NCM（带目标正则化和按结果分层集成的基础模型）以及 ColdNet（NCM 加 K-Means 冷启动增强），并包含两个改善列：$\Delta 1$ 衡量从 Baseline 到 ColdNet 的总改善，$\Delta 2$ 通过比较 NCM 与 ColdNet 来隔离 K-Means 的贡献。

冷启动群组（240K 样本，占 40.7%）取得最大收益：ColdNet 相比 NCM 实现 19.1% 的 MAE 改善（$\Delta 2$），并显著降低中位偏差（92.1%）。对于冷启动样本，NCM 相比基线将 MAE 降低 10.6%，ColdNet 的 K-Means 增强额外带来 19.1% 的改善，总降幅达到 27.6%。中位误差降低 82.8%（从 21.14 美元 降至 3.64 美元），中位偏差降低 92.1%，几乎消除了系统性偏差。重要的是，K-Means 仅对冷启动样本生效，暖启动预测保持不变，并提供严格改善保证；18.8% 的暖启动改善完全来自 NCM 的目标正则化。总体而言，ColdNet 实现了 20.4% 的 MAE 降低（从 270.46 美元 降至 215.38 美元）。

ColdNet 为什么有效。 82.8% 的中位误差降低表明 ColdNet 修正的是典型冷启动预测，而不仅是异常点。增强前，冷启动预测存在系统性正偏差（中位偏差 12.88 美元），说明 NCM 会高估历史特征缺失主体的结果；通过 K-Means 混合后，中位偏差降至 1.02 美元，接近零系统误差。27.6% 的冷启动总改善可拆分为两项互补贡献：NCM 的目标正则化通过学习平衡表征贡献 10.6%；K-Means 增强通过从相似训练样本迁移结果额外贡献 19.1%。这种乘法式收益说明两种机制解决的是互补的失败模式。

超参数敏感性。 对 18 组配置的综合调优（附录 F）表明：（1）局部性很重要，将 k 从 100 降至 10，可使 MAE 改善从 -17.4% 提升到 -19.1%；（2）分位数聚合至关重要，均值聚合会使 MAE 恶化 +1.3%；（3）性能稳健，所有分位数配置均实现 17-19% 的改善。

生产部署。 ColdNet 每周在美国市场处理超过 10 亿次预测，并实现 95% 的推荐覆盖率（之前排除冷启动案例的方法为 55%）；在欧盟的荷兰、瑞典和波兰市场合计处理 30 亿次预测，并计划到 2026 年第一季度末扩展到 12 个市场。该系统使 99.2% 由于历史画像不完整而未被充分服务的用户也能获得个性化干预。当前生产系统由 AWS Lambda 函数触发，进行每周推断和季度模型重训练。这些 Lambda 函数触发 AWS Step Functions，由后者编排通过 Cradle 进行数据收集，随后由 PySpark 脚本在 EMR 上进行大量数据预处理，最后使用 SageMaker 作业进行模型训练/推断。推断后，会为每个 offer 计算中位预测，并应用大量业务规则过滤错误预测。最终输出会传递给下游工程团队，并展示给终端客户（卖家）。

5 相关工作

神经因果模型。 CATE 估计的神经方法始于 TARNet 和 CFRNet [24]，它们通过积分概率度量学习平衡表征。DragonNet [25] 增加了带目标正则化的倾向头，而 CEVAE [19] 使用变分推断处理潜在混杂因子。GANITE [29] 采用对抗训练，SITE [28] 关注局部相似性保持。近期工作解决了具体挑战：[6] 提供理论基础，[11] 学习解耦表征，[14] 开发最优双重稳健估计器。然而，这些方法都假设存在充分重叠（处理率 >5%）且协变量完整，而这些假设在我们的场景中并不成立。在我们的条件下（0.3% 处理率、97.9% 冷启动），我们发现 DragonNet 在冷启动群组上产生负 R^2；CEVAE 的潜变量推断在极端稀疏下变得不稳定；GANITE 的对抗训练在严重类别不平衡下无法收敛。

计量经济学方法。 Double Machine Learning [4] 通过交叉拟合和 Neyman 正交性实现 $\sqrt{n}$ 一致性，但要求倾向得分远离 0 和 1。因果森林 [27, 1] 提供诚实置信区间，但难以处理高维稀疏特征。双重稳健方法 [2, 23] 结合了结果模型和倾向模型，但在极端不平衡下仍继承了倾向不稳定性。元学习器 [15]（S、T、X-learner）具有灵活性，但没有冷启动迁移机制。我们的半合成验证显示，DML 在 7.8% 处理率下由于倾向坍缩出现灾难性失败（CATE R^2 = -105.8）：得分集中在接近零的位置，违反正值性假设 [22, 5]。

冷启动与缺失数据。 冷启动问题在推荐系统中已被广泛研究：DropoutNet [26] 使用 dropout 模拟内容特征缺失；MeLU [16] 将元学习用于用户偏好估计；基于内容的方法 [18] 利用物品属性。然而，这些方法迁移的是预测，而不是反事实结构。它们无法保留处理效应 $\tau = \mu_1 - \mu_0$，因为它们没有分离的潜在结果头。在因果推断中，缺失数据方法 [20] 处理的是结果或处理的缺失，而非协变量缺失。迁移学习方法 [21] 假设源域和目标域共享结构，而当冷启动主体具有根本不同的特征分布时，这一假设会失败。ColdNet 独特地迁移两个潜在结果预测（μ_0, μ_1），从而保留反事实结构。

类别不平衡。 SMOTE [3] 通过插值生成合成少数类样本，但它假设不平衡是同质的，并且在高维空间中可能产生不现实样本。用于不平衡的集成方法 [10, 17] 通常采用统一重采样或成本敏感学习。我们的数据呈现异质性不平衡：处理率在不同结果层之间差异显著。统一重采样会破坏这一结构。ColdNet 的按结果分层集成通过确保每个模型看到完整处理组，同时维持按结果分层的多样化控制群体，从而保留异质性。

6 结论

我们提出了 ColdNet，这是一种神经因果架构，用于应对极端类别不平衡、结果稀疏和冷启动场景同时出现的问题。这些条件会导致现有方法失败。我们的三项创新协同工作：按结果分层的集成学习在保留不同结果层中异质处理率结构的同时，将有效不平衡从 1:256 降至 1:2；结合稀疏感知预处理的目标正则化通过反事实校正强制学习平衡表征，实现 0.910 的安慰剂有效性，并支持因果而非关联推断；基于聚类的冷启动增强通过保持局部性的分位数聚合，从相似训练样本迁移预测。ColdNet 在生产环境中每周处理超过 40 亿次预测，并实现 95% 的推荐覆盖率（美国市场中，此前方法

为 55%）。通过为 99.2% 历史画像不完整的用户提供准确的因果预测，ColdNet 有助于构建更具包容性的个性化系统，使新用户或低频用户不会系统性地处于不利地位，也证明了科学严谨性与大规模运营卓越性可以共存。

我们的评估局限于单一电商领域；若要推广到医疗、政策或其他数据特征不同的领域，还需要验证。与单模型相比，m 模型集成会增加训练时间和内存占用；受资源约束的部署可能受益于模型蒸馏或集成剪枝。冷启动定义（对 6 个特征使用析取准则）以及超参数（K, k, q, w）是针对我们特定数据集调优的，实践者应在自己的数据上验证这些选择。未来有前景的扩展方向包括：能够从数据特征中学习最优 K 的自适应聚类选择；通过保形推断或贝叶斯集成对冷启动预测进行不确定性量化；随着新的冷启动样本到来，使用在线学习更新聚类索引；以及扩展到连续处理或多值处理。

表 4：ColdNet 与既有工作在四个挑战维度上的定位。

方法	不平衡	冷启动	反事实	稀疏性
DragonNet [25]	×	×	✓	×
SITE [28]	×	×	✓	×
DML [4]	×	×	✓	×
DropoutNet [26]	×	✓	×	×
SMOTE [3]	✓	×	×	×
ColdNet（本文）	✓	✓	✓	✓

参考文献

为保留学术引用的准确性，参考文献条目保留原文格式。

[1] Susan Athey, Julie Tibshirani, and Stefan Wager. Generalized random forests. *The Annals of Statistics*, 47(2):1148-1178, 2019.

[2] Heejung Bang and James M. Robins. Doubly robust estimation in missing data and causal inference models. *Biometrics*, 61(4):962-973, 2005.

[3] Nitesh V. Chawla, Kevin W. Bowyer, Lawrence O. Hall, and W. Philip Kegelmeyer. SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16:321-357, 2002.

[4] Victor Chernozhukov, Denis Chetverikov, Mert Demirer, Esther Duflo, Christian Hansen, Whitney Newey, and James Robins. Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, 21(1):C1-C68, 2018.

[5] Richard K. Crump, V. Joseph Hotz, Guido W. Imbens, and Oscar A. Mitnik. Dealing with limited overlap in estimation of average treatment effects. *Biometrika*, 96(1):187-199, 2009.

[6] Alicia Curth and Mihaela van der Schaar. Nonparametric estimation of heterogeneous treatment effects: From theory to learning algorithms. In *International Conference on Artificial Intelligence and Statistics*, pages 1810-1818, 2021.

[7] Alicia Curth, David Svensson, Jim Weatherall, and Mihaela van der Schaar. Really doing great at estimating CATE? a critical look at ML benchmarking practices in treatment effect estimation. In *NeurIPS Datasets and Benchmarks Track*, 2021.

[8] Alexander D'Amour, Peng Ding, Avi Feller, Lihua Lei, and Jasjeet Sekhon. Overlap in observational studies with high-dimensional covariates. *Journal of Econometrics*, 221(2):644-654, 2021.

[9] Vincent Dorie, Jennifer Hill, Uri Shalit, Marc Scott, and Dan Cervone. Automated versus do-it-yourself methods for causal inference: Lessons learned from a data analysis competition. *Statistical Science*, 34(1):43-68, 2019.

[10] Mikel Galar, Alberto Fernandez, Edurne Barrenechea, Humberto Bustince, and Francisco Herrera. A review on ensembles for the class imbalance problem: Bagging-, boosting-, and hybrid-based approaches. *IEEE Transactions on Systems, Man, and Cybernetics, Part C*, 42(4):463-484, 2012.

[11] Negar Hassanpour and Russell Greiner. Learning disentangled representations for counterfactual regression. In *International Conference on Learning Representations*, 2020.

[12] Guido W. Imbens and Donald B. Rubin. *Causal Inference in Statistics, Social, and Biomedical Sciences*. Cambridge University Press, 2015.

[13] Jeff Johnson, Matthijs Douze, and Hervé Jégou. Billion-scale similarity search with GPUs. *IEEE Transactions on Big Data*, 7(3):535-547, 2019.

[14] Edward H. Kennedy. Towards optimal doubly robust estimation of heterogeneous causal effects. *Electronic Journal of Statistics*, 17(2):3008-3049, 2023.

[15] Sören R. Künzel, Jasjeet S. Sekhon, Peter J. Bickel, and Bin Yu. Metalearners for estimating heterogeneous treatment effects using machine learning. *Proceedings of the National Academy of Sciences*, 116(10):4156-4165, 2019.

[16] Hoyeop Lee, Jinbae Im, Seongwon Jang, Hyunsouk Cho, and Sehee Chung. MeLU: Meta-learned user preference estimator for cold-start recommendation. In *ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, pages 1073-1082, 2019.

[17] Ziwei Liu, Zhongqi Miao, Xiaohang Zhan, Jiayun Wang, Boqing Gong, and Stella X. Yu. Large-scale long-tailed recognition in an open world. In *IEEE Conference on Computer Vision and Pattern Recognition*, pages 2537-2546, 2019.

[18] Pasquale Lops, Marco de Gemmis, and Giovanni Semeraro. Content-based recommender systems: State of the art and trends. In *Recommender Systems Handbook*, pages 73-105. Springer, 2011.

[19] Christos Louizos, Uri Shalit, Joris M. Mooij, David Sontag, Richard Zemel, and Max Welling. Causal effect inference with deep latent-variable models. In *Advances in Neural Information Processing Systems*, volume 30, 2017.

[20] Wang Miao and Eric J. Tchetgen Tchetgen. On varieties of doubly robust estimators under missingness not at random with a shadow variable. *Biometrika*, 103(2):475-482, 2016.

[21] Sinno Jialin Pan and Qiang Yang. A survey on transfer learning. *IEEE Transactions on Knowledge and Data Engineering*, 22(10):1345-1359, 2010.

[22] Maya L. Petersen, Kristin E. Porter, Susan Gruber, Yue Wang, and Mark J. van der Laan. Diagnosing and responding to violations in the positivity assumption. *Statistical Methods in Medical Research*, 21(1):31-54, 2012.

[23] James M. Robins, Andrea Rotnitzky, and Lue Ping Zhao. Estimation of regression coefficients when some regressors are not always observed. *Journal of the American Statistical Association*, 89(427):846-866, 1994.

[24] Uri Shalit, Fredrik D. Johansson, and David Sontag. Estimating individual treatment effect: Generalization bounds and algorithms. In *International Conference on Machine Learning*, pages 3076-3085, 2017.

[25] Claudia Shi, David Blei, and Victor Veitch. Adapting neural networks for the estimation of treatment effects. In *Advances in Neural Information Processing Systems*, volume 32, 2019.

[26] Maksims Volkovs, Guangwei Yu, and Tomi Poutanen. DropoutNet: Addressing cold start in recommender systems. In *Advances in Neural Information Processing Systems*, volume 30, 2017.

[27] Stefan Wager and Susan Athey. Estimation and inference of heterogeneous treatment effects using random forests. *Journal of the American Statistical Association*, 113(523):1228-1242, 2018.

[28] Liuyi Yao, Sheng Li, Yaliang Li, Mengdi Huai, Jing Gao, and Aidong Zhang. Representation learning for treatment effect estimation from observational data. In *Advances in Neural Information Processing Systems*, volume 31, 2018.

[29] Jinsung Yoon, James Jordon, and Mihaela van der Schaar. GANITE: Estimation of individualized treatment effects using generative adversarial nets. In *International Conference on Learning Representations*, 2018.

附录

A 损失函数直觉

本附录对正文公式（1）中的 ColdNet 损失函数各项给出详细直觉解释。

结果预测（第一项）。 加权 MSE 训练结果头 μ_0 和 μ_1 来预测观测结果。选择器 $T\cdot\mu_1+(1-T)\cdot\mu_0$ 会根据处理分配将每个样本路由到对应的头：处理主体训练 μ_1，控制主体训练 μ_0。

处理预测（第二项）。 二元交叉熵训练倾向头 $\pi(X)$ 来预测处理分配。这使模型能够学习谁会接受处理，并识别数据中的选择模式。

目标正则化（第三项）。 cc 项是支持因果而非关联推断的关键创新。如果没有该项，模型学习的是 $E[Y\mid T,X]$，即处理与结果之间的关联关系；这种关系会将处理的因果效应与选择偏差混淆。cc 项在损失函数中实现逆倾向加权：对于处理主体（$T=1$），$cc=1/\pi(X)$，当倾向较低时该值较大，会提升那些类似控制群体的罕见处理主体权重。对于控制主体（$T=0$），$cc=-1/(1-\pi(X))$，当倾向较高时其绝对值较大，会提升那些基于协变量“本应被处理”的控制主体权重。这种重新加权创建了一个伪总体，在其中处理分配与协变量独立，从而满足因果识别条件。因此，共享表征 $\Phi(X)$ 学习的是能够预测潜在结果 $Y(0)$ 和 $Y(1)$ 的特征，而不只是观测结果 Y，进而打破“谁选择处理”与“处理效果”之间的混杂。

可学习的 ϵ。 缩放参数 ϵ 与网络权重联合学习，而不是作为固定超参数。该设计有三个目的：（1）自适应正则化强度：结果预测与因果校正之间的最优平衡会随数据集而变化，取决于处理不平衡严重程度和混杂结构；可学习的 ϵ 允许模型在训练中发现该平衡。（2）基于梯度的校准：随着倾向头 $\pi(X)$ 在训练中改善，cc 项幅度会变化；可学习的 ϵ 会自动重新校准，以维持稳定梯度。（3）对倾向极端值的鲁棒性：在严重不平衡（0.3% 处理率）下，倾向得分接近边界值，导致 cc 爆炸；学习到的 ϵ 会收缩以进行补偿，防止梯度不稳定，同时保留因果校正信号。实践中，ϵ 会收敛到较小值（约 0.01-0.1），说明即便适度的因果校正也能显著改善表征学习。

B 稀疏感知预处理细节

本附录详细描述用于处理结果稀疏的预处理技术。

B.1 真正无响应者与稀疏观测

真正无响应者 是指处理确实没有效果的主体：$\mu_0(X)\approx\mu_1(X)\approx 0$，因此 $\tau(X)\approx 0$。无论是否接受处理，这些个体都会表现出零结果；它们代表结果分布中的结构性零。例如，从不购买某个商品类目的客户，即使给出该类目的促销优惠，也很可能没有响应。

稀疏观测 是指具有正处理潜力（$\tau(X)>0$）但由于观察窗口有限或随机波动，恰好显示零观测控制结果的主体。这些个体会对处理产生响应，但在训练数据中，其基线行为看起来与真正无响应者相同。

B.2 预处理技术

保留零值的 MinMax 缩放。 我们将结果缩放到 $[0,2.5)$，同时显式保留零值：当 $y>0$ 时，$y'=2.5\cdot(y-y_{min})/(y_{max}-y_{min})$；否则 $y'=0$。这保持了真实零值（结构性无响应）与小正值（弱但真实的响应）之间的关键区别。

结果 winsorization 截尾。 我们在第 99.5 百分位截断结果：$y'=min(y,y_{p99.5})$。这可以防止极端异常值主导 MSE 损失并扭曲梯度更新。

分层批采样。 我们构建训练批次时对非零结果过采样，确保每个批次大约包含 30% 正例（原始数据中为 2.4%）。

B.3 预处理如何支持目标正则化

这些预处理技术对于 cc 项正确发挥作用至关重要：

- **零值保留支持稀疏观测检测**。 通过显式保留零值，我们确保 cc 项的重新加权会放大正确信号：那些尽管可能接受处理（高倾向控制组）却显示零结果的主体，对于反事实来说真正具有信息量。
- **截尾稳定 cc 加权梯度**。 在极端稀疏下，罕见的高值结果可能主导 MSE 损失。截尾限制了结果幅度，确保即使对于大幅上调权重的样本，cc 加权梯度仍然稳定。
- **分层批采样确保 cc 作用于信息充分的批次**。 分层采样确保每个批次包含足够的非零结果，使 cc 项的重新加权能产生有意义的梯度更新，从而区分处理效应与噪声。

C NCM 架构消融研究

在应用 K-Means 冷启动增强之前，我们进行综合消融研究，以选择最优的神经因果模型（NCM）架构。这项研究很关键，因为所选架构是后续所有创新的基础，包括按结果分层的集成学习、基于聚类的冷启动预测迁移以及生产部署。基础 NCM 必须：（1）在严重类别不平衡下优于 DML 等经典计量经济学方法；（2）产生因果有效的估计（而非关联预测）；（3）在暖启动和冷启动群组中都能提供稳健预测。

C.1 模型配置

我们评估四种逐步复杂的架构，它们在是否使用倾向建模、目标正则化和辅助分类方面不同。每个配置使用相同的超参数、训练数据和评估协议，只改变架构组件。

消融 1：TARNet（基线）。 Treatment-Agnostic Representation Network [24] 使用分别的结果头 $\mu_0(X)$ 与 $\mu_1(X)$，并在共享表征 $\Phi(X)$ 上运行，但不包含倾向建模。损失函数仅包含结果 MSE：$L=MSE(Y,T\cdot\mu_1+(1-T)\cdot\mu_0)$，其中 $\alpha=0,\beta=0,\gamma=0$。该配置无法预测处理分配，只学习关联关系 $E[Y\mid T,X]$。

消融 2：DragonNet（无目标正则化）。 增加倾向头 $\pi(X)=P(T=1\mid X)$ 和二元交叉熵损失：$L=MSE(Y,\hat{Y})+\alpha\cdot BCE(T,\pi)$，其中 $\alpha=1,\beta=0,\gamma=0$。倾向头支持处理预测，但不使用倾向得分来强制平衡表征。模型能识别选择模式，但仍学习关联关系而非因果关系。

消融 3：DragonNet（完整）。 完整 DragonNet 架构 [25]，同时包含倾向头和目标正则化：$L=MSE(Y,\hat{Y})+\alpha\cdot BCE(T,\pi)+\beta\cdot MSE(Y,\hat{Y}+\epsilon\cdot cc)$，其中 $\alpha=1,\beta=1,\gamma=0$。反事实校正项 $cc=T/\pi(X)-(1-T)/(1-\pi(X))$ 强制共享表征学习无论处理分配如何都能预测结果的特征，从而支持因果而非关联推断。

消融 4：DragonNet+GMS。 在 DragonNet 上增加辅助 GMS（结果）分类器头，用于预测结果是否非零，并使用加权 MSE 损失上调非零结果权重：$L=Weighted\text{-}MSE(Y,\hat{Y})+\alpha\cdot BCE(T,\pi)+\beta\cdot MSE(Y,\hat{Y}+\epsilon\cdot cc)+\gamma\cdot BCE(Y_{nonzero},\hat{p}_{GMS})$，其中 $\alpha=1,\beta=1,\gamma=1$。该配置通过显式建模结果分布来更好处理零膨胀结果。

C.2 评估协议

我们在相同数据（590,255 个样本，40.7% 冷启动）上训练所有模型，并使用生产超参数：批大小 256、学习率 3.98×10^{-4}、dropout 0.236、共享隐藏维度 512、结果隐藏维度 64、50 个 epoch 和 patience 为 15 的早停。

因果有效性的安慰剂测试。 安慰剂测试是验证模型学习因果关系而非关联模式的黄金标准。这一区别至关重要：学习关联的模型会根据谁通常接受处理来预测处理效应，而不是根据处理真正产生的效果来预测。此类模型会向看起来像过去处理对象的主体推荐干预，不管处理是否真正有帮助，从而浪费资源并错失机会。

测试流程。 我们只取控制组（$T=0$），随机分配伪处理标签，并计算伪处理子组与伪控制子组之间的预测处理效应差异。由于实际上没有发生处理，所有主体的真实处理效应都恰好为零。因果有效的模型应预测无差异，任何检测到的效应都是虚假的，来自模型将协变量模式与处理效应混淆。

解释。 我们运行 200 次置换并报告 p-value：高值（接近 1.0）表示模型在安慰剂条件下正确发现无效应；低值则表明模型检测到虚假处理效应。低 p-value 是严重失败模式：它意味着模型会基于主体协变量画像而不是真实处理收益来推荐处理，从而系统性错配干预。在会影响数百万主体处理决策的生产部署中，因果学习和关联学习之间的区别就是有效个性化与昂贵噪声之间的区别。

C.3 结果

表 5：590K 测试样本上的 NCM 架构消融研究。所有误差值单位为美元。

类别	指标	TARNet	DN（No TR）	DN	DN+GMS
Configuration	Propensity Head	×	✓	✓	✓
Configuration	Targeted Reg.	×	×	✓	✓
Outcome Prediction	RMSE (USD)	1,319.89	1,933.71	1,939.61	1,190.32
Outcome Prediction	MAE (USD)	243.62	238.94	246.27	253.55
Outcome Prediction	WAPE	0.815	0.800	0.824	0.849
Propensity Quality	Treatment AUC	0.500	0.919	0.926	0.922
Propensity Quality	Treatment F1	0.644	0.860	0.881	0.877
Causal Validity	Placebo p-value	0.284	0.085	0.910	0.836
Median Error (USD)	Overall	38.50	31.71	28.03	74.19
Median Error (USD)	Treatment Group	77.02	75.98	71.11	132.83
Tail Error (USD)	Control P90	363.19	319.10	318.71	336.31
Tail Error (USD)	Treatment P95	982.13	882.42	875.74	901.41

表 5 展示了四类指标的综合结果。出现了以下关键发现。

倾向建模对于处理预测必不可少。 不含倾向头的 TARNet 的 Treatment AUC = 0.500（随机水平），意味着共享表征不包含任何关于处理分配的信息。加入倾向头（DragonNet 变体）后，处理预测大幅提升到 AUC > 0.91，使模型能够识别数据中的选择模式。这一能力对于理解谁会接受处理以及原因至关重要。

目标正则化实现最佳因果有效性。 带目标正则化的 DragonNet 获得最高安慰剂 p-value（0.910），远高于无 TR 的 DragonNet（0.085）和 TARNet（0.284）。这说明目标正则化成功强制学习平衡表征；当控制组被随机拆分时，模型正确识别出没有虚假处理效应。关键的是，即使无 TR 的 DragonNet 具有倾向头，它在安慰剂测试上反而表现最差，说明如果没有强制平衡表征的正则化机制，仅靠倾向建模是不够的。倾向头学到了谁会接受处理，但没有目标正则化时，结果头会将“谁选择处理”与“处理效果”混淆。

DragonNet 实现最佳典型预测准确性。 虽然 DragonNet+GMS 通过更贴近结果分布实现最佳 RMSE（1,190.32 美元），但 DragonNet 的中位误差最低：总体中位误差为 28.03 美元（TARNet 为 38.50 美元，无 TR DragonNet 为 31.71 美元，

DragonNet+GMS 为 74.19 美元），处理组中位误差为 71.11 美元。对于 CATE 估计，中位误差比均值误差更重要，因为它反映典型预测质量，不会被极端异常点主导。

DragonNet 实现最佳尾部误差表现。 DragonNet 获得最低控制组 P90 误差（318.71 美元）和处理组 P95 误差（875.74 美元），说明即使在分布尾部也具有稳健表现。这对于生产部署至关重要，因为极端预测误差可能产生过大的业务影响。

DragonNet+GMS 降低了典型预测质量。 尽管获得最佳 RMSE，DragonNet+GMS 产生了明显更差的中位误差（总体 74.19 美元，处理组 132.83 美元）以及较低的因果有效性（p-value = 0.836）。辅助分类器和加权 MSE 改善了对结果分布的拟合，但代价是降低因果有效性和典型预测质量。这表明，对于因果推断来说，优化原始结果预测准确性并不是正确目标，平衡表征更重要。

C.4 模型选择理由

我们选择带目标正则化的 DragonNet（消融 3）作为 NCM 基础，用于所有后续实验和生产部署，因为它实现了：

1. **最佳倾向校准**：Treatment AUC = 0.926，F1 = 0.881。这对于理解选择模式和支持基于倾向的分析至关重要。
2. **最强因果有效性**：安慰剂 p-value = 0.910。模型在安慰剂条件下正确识别无虚假处理效应，说明它学习的是因果关系而非关联关系。
3. **最低典型预测误差**：总体中位误差 28.03 美元，处理组中位误差 71.11 美元。多数预测上表现稳健。
4. **最佳尾部表现**：P90 和 P95 误差在所有配置中最低，这对生产可靠性至关重要。

DragonNet 中的目标正则化会将预测压缩到更保守的估计；这优先保证无偏 CATE 估计，而不是原始结果预测准确性。对于因果推断应用，这是合理取舍。该基础随后通过按结果分层的集成学习（处理类别不平衡）和基于 K-Means 聚类的冷启动预测迁移（处理画像不完整）得到增强。

D 半合成验证：其他 DGP

表 6 和表 7 展示了 Linear 与 Interaction DGP 的结果，用于补充正文中的 Sine 结果。三种 DGP 都表现出一致模式：DML 在类别不平衡下灾难性失败（负 CATE R^2），NCM 稳健估计（正 CATE R^2，$\sqrt{PEHE}$ 好 12-14 倍），且分布尾部估计稳定。

所有 DGP 上的关键观察：

- DML 的 CATE R^2 始终为负（-77.0 到 -105.8），说明在所有函数形式下预测都比常数更差。
- NCM 的 CATE R^2 始终为正（0.44 到 0.49），说明能稳健捕捉异质性。
- NCM 在所有 DGP 上使 $\sqrt{PEHE}$ 改善 12-14 倍。
- DML 具有严重尾部偏差（QTE P10 Bias：-0.20 到 -0.28；QTE P90 Bias：+0.20 到 +0.22），而 NCM 保持稳定估计（±0.04-0.07）。
- ATT 估计显示 NCM 有 7-13 倍改善，这对定向决策至关重要。

这些结果确认，NCM 在类别不平衡下相对于 DML 的优势，在不同处理效应函数形式上都是一致的：从简单线性效应，到非线性周期函数，再到特征交互。

表 6：半合成验证：Linear DGP（$\tau(x)=\beta^\top x$）。

指标	Mean Baseline	DML	NCM	NCM vs DML
$\sqrt{PEHE}$ ↓	0.121	1.068	0.086	好 12.4×

指标	Mean Baseline	DML	NCM	NCM vs DML
CATE R² ↑	0.000	-77.0	0.494	+77.5 pts
CATE Correlation ↑	0.000	0.341	0.708	好 2.1×
ATE Rel. Bias % ↓	+0.2%	-9.2%	-3.8%	小 2.4×
ATT Bias ↓	+0.013	-0.053	-0.004	小 13.3×
QTE P10 Bias ↓	+0.140	-0.276	+0.036	小 7.7×
QTE P90 Bias ↓	-0.135	+0.195	-0.069	小 2.8×

表 7：半合成验证：Interaction DGP（$\tau(x)=x_1 \cdot x_2$）。

指标	Mean Baseline	DML	NCM	NCM vs DML
$\sqrt{PEHE}$ ↓	0.123	1.138	0.089	好 12.8×
CATE R² ↑	0.000	-84.6	0.471	+85.1 pts
CATE Correlation ↑	0.000	0.258	0.694	好 2.7×
ATE Rel. Bias % ↓	+0.4%	+7.5%	+0.9%	小 8.3×
ATT Bias ↓	+0.023	+0.042	+0.006	小 7.0×
QTE P10 Bias ↓	+0.153	-0.284	+0.073	小 3.9×
QTE P90 Bias ↓	-0.146	+0.203	-0.064	小 3.2×

E 因果推断评估指标

我们使用按三类组织的综合指标评估因果模型：个体层处理效应指标（需要真实 CATE，仅半合成环境可用）、总体层处理效应指标，以及生产结果预测指标。

E.1 个体层处理效应指标

这些指标需要真实个体处理效应 $\tau_i = Y_i(1) - Y_i(0)$，该值仅在同时生成两个潜在结果的半合成验证中可用。

- $\sqrt{PEHE}$**（异质性效应估计精度的平方根）**：个体处理效应预测的均方根误差：

$$\sqrt{PEHE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}\left(\hat{\tau}(x_i) - \tau(x_i)\right)^2}$$

其中 $\hat{\tau}(x_i) = \hat{\mu}_1(x_i) - \hat{\mu}_0(x_i)$ 是预测 CATE，$\tau(x_i) = Y_i(1) - Y_i(0)$ 是真实 CATE。越低越好。这是个体层准确性的主要指标，用于衡量模型在总体中捕捉异质性处理效应的能力。

- **CATE R²**：处理效应预测的决定系数，用于衡量解释方差：

$$R^2_{CATE} = 1 - \frac{\sum_{i=1}^{n}\left(\hat{\tau}_i - \tau_i\right)^2}{\sum_{i=1}^{n}\left(\tau_i - \acute{\tau}\right)^2}$$

其中 $\acute{\tau} = \frac{1}{n}\sum_i \tau_i$ 是真实处理效应均值。取值范围从 $-\infty$ 到 1；1 表示完美预测，0 表示与预测常数均值等同，负值表示比常数均值更差，是模型坍缩的关键失败信号。

- **CATE Correlation**：预测个体处理效应与真实个体处理效应之间的 Pearson 相关：

$$\rho_{CATE}=\frac{Cov(\hat{\tau},\tau)}{\sigma_{\hat{\tau}}\cdot\sigma_{\tau}}$$

该指标衡量用于定向决策的排序准确性。即使效应幅度估计存在偏差，该指标也很重要，因为定向决策通常只需要正确排序处理效应。

E.2 总体层处理效应指标

这些指标评估聚合处理效应估计质量。

- **ATE（平均处理效应）**：总体层期望处理效应：

$$ATE=E\left[Y(1)-Y(0)\right]=\frac{1}{n}\sum_{i=1}^{n}\tau_i$$

- **ATE 相对偏差 %**：估计 ATE 与真实 ATE 的百分比偏离：

$$ATE\,Rel.Bias=\frac{\widehat{ATE}-ATE}{ATE}\times 100\%$$

其中 $\widehat{ATE}=\frac{1}{n}\sum_{i}\hat{\tau}_i$。该指标衡量总体层效应的系统性高估或低估。

- **ATT（已处理者平均处理效应）**：实际接受处理人群的期望处理效应：

$$ATT=E\left[Y(1)-Y(0)\mid T=1\right]=\frac{1}{n_1}\sum_{i:T_i=1}\tau_i$$

其中 $n_1=\sum_{i}T_i$ 是已处理主体数量。

- **ATT Bias**：估计 ATT 与真实 ATT 的绝对偏离：

$$ATT\,Bias=\widehat{ATT}-ATT$$

这对定向应用至关重要，用于衡量实际被干预人群上的效应估计准确性。

- **QTE（分位数处理效应）**：效应分布中特定分位数上的处理效应：

$$QTE_q=Q_q(\tau)-Q_q(0)\approx Q_q\left(\{\tau_i\}_{i=1}^{n}\right)$$

其中 Q_q 表示第 q 个分位数。我们报告 P10（第 10 百分位）和 P90（第 90 百分位）的 QTE，用于评估极端响应者所在分布尾部的估计质量。

- **QTE P10/P90 Bias**：估计分位数处理效应与真实值的偏离：

$$QTE_q\,Bias=\widehat{QTE}_q-QTE_q$$

该指标测试分布尾部稳定性。平均表现良好的模型，仍可能在极端响应者上出现严重不稳定。

E.3 倾向得分指标

- **Propensity AUC**：处理预测的 ROC 曲线下面积：

$$AUC=P\left(\pi(X_i)>\pi(X_j)\mid T_i=1,T_j=0\right)$$

该指标衡量倾向头区分处理主体和控制主体的能力。AUC 越高表示倾向估计越好，而这对于反事实校正项 cc 正确发挥作用至关重要。

E.4 生产结果预测指标

这些指标在观察数据上评估结果预测质量，而此类数据没有真实处理效应。准确的结果预测是准确 CATE 估计的必要条件，尽管不是充分条件。

- **MAE（平均绝对误差）**：平均绝对预测误差：

$$MAE=\frac{1}{n}\sum_{i=1}^{n}\left|y_i-\hat{y}_i\right)$$

这是整体预测准确性的主要指标。MAE 对异常值较为鲁棒（不同于 RMSE），且可用结果单位解释。

- **中位绝对误差**：绝对误差的第 50 百分位：

$$MedianError=median\left(\left\{\left|y_i-\hat{y}_i\right)\right\}_{i=1}^{n}\right)$$

该指标捕捉“平均”样本的典型预测质量，不受极端误差影响。在零膨胀分布下，中位误差可揭示模型是否能为大多数样本正确预测零值。

- **中位偏差**：带符号误差的第 50 百分位：

$$MedianBias=median\left(\left\{y_i-\hat{y}_i\right\}_{i=1}^{n}\right)$$

该指标检测系统性高估或低估。接近零的偏差表示模型学到了正确的结果分布。它对处理效应估计尤其重要，因为有偏的结果预测会传导为有偏的 CATE 估计。

- **WAPE（加权绝对百分比误差）**：按结果规模归一化的误差：

$$WAPE=\frac{\sum_{i=1}^{n}\left|y_i-\hat{y}_i\right)}{\sum_{i=1}^{n}\left|y_i\right)}$$

该指标支持跨不同结果尺度的比较。WAPE 接近 1.0 表示误差与结果量级相当；对于多数结果为零的高度稀疏分布，这是可接受的。

F 超参数敏感性分析

为理解各超参数贡献并验证设计选择，我们在 18 组配置上进行系统扫描。表 8 给出综合结果，每一行改变一个超参数，同时保持其他参数为默认值（$n_{clusters}=20$、$k_{neighbors}=25$、$w_{NCM}=0.1$、$q=0.45$）。

分析得出几个关键发现。

邻居数量（$k_{neighbors}$）影响最大。 将 $k_{neighbors}$ 从 100 降到 10，使冷启动 MAE 改善从 -17.4% 提升到 -19.1%，说明更局部化的预测优于更宽泛的平均。冷启动样本受益于紧密匹配的邻居，而不是来自更大邻域的平滑估计。改善具有单调性：更小邻域通常带来更好准确性。

分位数聚合至关重要。 使用均值聚合代替分位数聚合，会使冷启动 MAE 恶化 +1.3%，使 K-Means 方法从有益变为有害。这一关键失败源于冷启动结果分布的零膨胀特性：均值聚合会过度加权罕见高值邻居，产生系统性偏高预测。分

位数聚合（第 45 百分位）产生了与多数零值或低值结果一致的保守估计。这一发现具有重要启示：采用均值聚合的朴素实现会降低性能。

聚类数量不敏感。 $n_{clusters} \in \{10, 20, 50, 100\}$ 的表现几乎相同（冷启动 MAE 改善 -18.2% 到 -18.3%）。这种鲁棒性表明，K-Means 分区主要用于加速近邻搜索，而不是学习有意义的聚类结构；真正发挥主要作用的是聚类内的 FAISS 近邻检索。该不敏感性简化了部署：实践者不需要仔细调优聚类数量。

表 8：不同超参数配置下冷启动 MAE 改善（%）。在 240K 冷启动测试样本上评估。负值表示改善（MAE 越低越好）。

超参数	取值	Cold MAE Δ%	Overall MAE Δ%	Cold Median Δ%
nclusters	10	-18.3%	-3.4%	-83.4%
nclusters	20	-18.2%	-3.4%	-83.4%
nclusters	50	-18.3%	-3.4%	-83.2%
nclusters	100	-18.2%	-3.4%	-83.3%
kneighbors	10	-19.1%	-3.6%	-82.8%
kneighbors	25	-18.2%	-3.4%	-83.4%
kneighbors	50	-17.7%	-3.3%	-83.4%
kneighbors	100	-17.4%	-3.3%	-83.6%
wNCM	0.0	-17.7%	-3.3%	-100.0%
wNCM	0.1	-18.2%	-3.4%	-83.4%
wNCM	0.2	-18.0%	-3.4%	-73.4%
wNCM	0.3	-17.3%	-3.3%	-64.4%
Aggregation	mean	+1.3%	-0.3%	-45.4%
Aggregation	q = 0.35	-17.9%	-3.4%	-84.1%
Aggregation	q = 0.40	-18.2%	-3.4%	-83.9%
Aggregation	q = 0.45	-18.2%	-3.4%	-83.4%
Aggregation	q = 0.50	-17.9%	-3.4%	-82.6%

NCM 权重对 MAE 影响较小。 $w_{NCM} \in \{0.0, 0.1, 0.2, 0.3\}$ 都实现了 17-18% 的冷启动 MAE 改善。然而，$w_{NCM} = 0.0$（纯聚类预测）会消除任何 NCM 贡献，可能牺牲预测多样性。我们选择 $w_{NCM} = 0.1$，以保留最小的 NCM 信号，同时主要依赖基于聚类的估计。注意，$w_{NCM} = 0.0$ 实现 -100% 的中位误差降低，是因为 NCM 的系统性过预测被完全移除。

跨配置表现稳健。 所有基于分位数的配置都实现了 17-19% 的冷启动 MAE 改善，说明 K-Means 方法对合理范围内的超参数选择具有鲁棒性。这种稳定性对于生产部署很关键：该方法无需大量调优即可部署，降低了运营复杂度，并使没有深厚超参数优化经验的实践者也能使用。

最终配置选择。 基于该综合分析，我们选择 $\left(n_{clusters} = 20, k_{neighbors} = 10, w_{NCM} = 0.1, q = 0.45\right)$ 作为最终配置，因为它获得最佳冷启动 MAE 改善（-19.1%），同时保持设置可解释和计算效率高。20 个聚类提供了足够粒度且不会产生过高计算开销，10 个邻居确保了局部化预测迁移。

G ColdNet 算法

算法 1 展示了用于基于聚类冷启动增强的完整 ColdNet 流程。

算法 1：ColdNet：用于反事实预测的基于聚类冷启动增强。 算法包含三个阶段：（0）按结果分层的集成预处理，通过在完整处理组与分层控制子集上训练 M 个模型来处理极端类别不平衡；（1）离线索引构建，建立一个可搜索的 FAISS 索引，其中冷启动训练样本通过 K-Means 聚类；（2）在线推断，暖启动样本直接路由至 NCM 输出，而冷启动样本通过从相似训练样本进行保持局部性的预测迁移来增强。超参数：$M = 10$ 个集成模型、$K = 20$ 个聚类、$k = 10$ 个邻居、$w = 0.1$ NCM 权重、$q = 0.45$ 聚合分位数。

```
超参数：M（集成规模）、K（聚类数）、k（邻居数）、w（NCM 权重）、q（分位数）
输入：原始数据 D = {(xi, ti, yi)}_{i=1}^N，冷启动掩码 C

// 阶段 0：按结果分层的集成预处理
Dtreat ← {(xi, yi): ti = 1}                        // 提取处理组（数据的 0.3%）
Dctrl  ← {(xi, yi): ti = 0}                        // 提取控制组
将 Dctrl 分层为 5 个结果分箱：zero, p50, p75, p90, max
将 Dctrl 划分为 M 个互不重叠的子集 {Dctrl^(1), ..., Dctrl^(M)}，并保留分层结构
对每个 m ∈ {1, ..., M}：
    Dtrain^(m) ← Dtreat ∪ Dctrl^(m)                // 全部处理组 + 一个控制子集
    使用公式（1）在 Dtrain^(m) 上训练 NCM 模型 Mm
结束

// 阶段 1：离线冷启动索引构建
 Dcold ← {(xi, yi): i ∈ Ctrain}                    // 提取冷启动群组
S ← StandardScaler.fit({xi: (xi, yi) ∈ Dcold})     // 拟合特征缩放器
Xscaled ← S.transform({xi})                        // 标准化特征
{c1, ..., cK} ← KMeans.fit(Xscaled, K)             // 聚类中心
对每个聚类 j ∈ {1, ..., K}：
    Dj ← {(xi, yi) ∈ Dcold: assign(xi)=j}          // 聚类 j 中的样本
    Xj ← {xi: (xi, yi) ∈ Dj}                       // 特征向量
    Xj_norm ← L2Normalize(Xj)                      // 单位范数，用于余弦相似度
    Ij ← FAISS.IndexFlatIP(Xj_norm)                // 内积索引
    Yj ← {yi: (xi, yi) ∈ Dj}                       // 存储结果
结束

// 阶段 2：在线反事实推断
输入：测试样本 x*，NCM 预测 (μ0^*, μ1^*)，冷启动指示 c*
输出：增强预测 (μ~0^*, μ~1^*)
如果 c* = False:                                   // 暖启动样本
    返回 (μ0^*, μ1^*)                              // NCM 预测不变
否则：
    // 冷启动样本：应用保持局部性的迁移
    x*_scaled ← S.transform(x*)                    // 应用拟合好的缩放器
    j* ← arg min_j ||x*_scaled - cj||_2            // 分配到最近聚类中心
    x*_norm ← L2Normalize(x*_scaled)               // 归一化查询
    Nk ← Ij*.search(x*_norm, k)                    // 检索 k 个最近邻
    YN ← {Yj*[i]: i ∈ Nk}                          // 邻居结果
    y_cluster^ ← Qq(YN)                            // 分位数鲁棒聚合
    μ~0^* ← w · μ0^* + (1-w) · y_cluster^          // 混合控制潜在结果头
    μ~1^* ← w · μ1^* + (1-w) · y_cluster^          // 混合处理潜在结果头
    返回 (μ~0^*, μ~1^*)
结束
```

H 数据集细节

本附录全面记录实验中使用的所有数据集，包括数据来源、预处理步骤和特征定义。

H.1 生产级电商数据集

H.1.1 原始生产数据

原始观察数据集包含来自某大型电商平台的卖家-offer 报名决策以及后续绩效结果。

关键洞察： 处理样本出现正结果的可能性比控制样本高 29 倍（64.71% vs. 2.20%），说明观察数据中存在强选择偏差，而这正是因果推断方法必须解决的挑战。

H.1.2 平衡训练集（A）

用于 NCM 和 ColdNet 训练。该数据集通过按结果分层采样创建，在丰富处理样本的同时保持冷启动表示。

H.1.3 不平衡训练集（B）

用于 Baseline DragonNet，以证明仅靠数据规模无法克服冷启动挑战。

H.1.4 平衡测试集（C）

所有方法都在该相同测试集上评估，以保证公平比较。

H.2 冷启动特征定义

如果以下六个历史活动特征中任一为零，我们即将样本归类为冷启动。这些特征覆盖两个粒度（offer 级和 ASIN 级）以及两个时间窗口（90 天和 365 天）。

特征语义。 六个特征在两个聚合层级上捕捉历史销售活动：

- **Offer 级特征（4 个特征）**：跟踪特定卖家-商品组合的表现。具有零 offer 级历史的 offer，表示该精确商品 listing 从未售出，即使底层产品（ASIN）可能由其他卖家销售过。
- **ASIN 级特征（2 个特征）**：跟踪跨所有卖家的产品总体表现。具有零 ASIN 级历史的 offer 表示无论卖家是谁，该产品都没有市场销售历史。

析取准则。 OR 逻辑分类可全面覆盖不完整画像。只要 offer 在 offer 级或 ASIN 级任一层面缺乏历史活动，就会被标记为冷启动，因为任一缺口都表示缺少可靠神经模型预测所需的历史信号。该准则覆盖：

- 原始样本的 97.9%（分层采样前）
- 平衡训练集的 58.6%（按结果分层采样后）
- 平衡测试集的 40.7%

特征选择理由。 这六个特征被选中，是因为它们直接衡量历史销售活动，而这是神经因果模型预测处理响应的主要信号。对于冷启动样本，商品类目、价格和卖家特征等仍然可用，并可支持基于聚类的增强（第 2.5 节）；但缺少历史活动特征会从根本上限制模型从历史行为模式中学习的能力。

H.3 半合成数据集

用于具有真实 CATE 的 NCM vs. DML 验证。

H.3.1 数据生成

来源： 900 万生产样本，72 个数值特征（删除 ID、类别特征和模式匹配列之后）。

特征处理： MinMax 缩放到 $[0,1)$ 范围。

处理效应生成： 三种数据生成过程（DGP）：

- **Sine：** $\tau(x)=\sin(weightedfeatures)$ - 非线性、周期性异质性
- **Linear：** $\tau(x)=\beta\cdot x$ - 简单线性异质性

- **Interaction：** $\tau(x) = x_1 \cdot x_2$ - 特征交互效应

处理效应尺度： $\tau = 2.0$（按结果标准差缩放）。

H.3.2 数据集统计

H.3.3 模式

H.4 实验设计摘要

表 16 总结了每种方法用于训练和评估的数据集。

关键设计决策：

1. **分层采样：** 原始数据存在极端不平衡（0.39% 处理率、99.25% 冷启动）。基于结果的分层采样创建平衡训练数据（45.9% 处理率），同时保留冷启动分布（58.6%）。
2. **相同测试集：** 所有方法（NCM、ColdNet、Baseline DragonNet）都在相同的 590K 平衡测试集上评估，以保证公平比较。
3. **基线使用不平衡数据：** DragonNet 基线在 960 万不平衡数据上训练，以证明单纯的数据规模（6 倍更多数据）无法在没有适当架构的情况下克服冷启动问题。
4. **半合成验证：** 真实 CATE 支持评估处理效应估计质量，而不仅仅是预测准确性；这对因果推断非常关键。

表 9：原始生产数据统计。按结果分层采样前的原始电商数据集。

属性	Train	Test
Total Samples	180,111,727	48,996,865
Features	161	161
Treatment Rate	0.39%	0.39%
Cold-Start Rate	99.25%	99.25%
Outcome > Threshold	2.44%	2.44%
Outcome Rate (Treated)	64.71%	-
Outcome Rate (Control)	2.20%	-

表 10：平衡训练集（A）统计。

属性	值
Total Samples	1,530,903
Features	161
Treatment Rate	45.87%
Treated Samples	702,286
Control Samples	828,617
Cold-Start Samples	897,443 (58.62%)
Warm Samples	633,460 (41.38%)

表 11：不平衡训练集（B）统计。

属性	值
Total Samples	9,587,881
Features	161
Treatment Rate	8.9%
Cold-Start Samples	5,178,941 (54.0%)
Warm Samples	4,408,940 (46.0%)

表 12：平衡测试集（C）统计。

属性	值
Total Samples	590,255
Features	161
Treatment Rate	24.9%
Treated Samples	147,005
Control Samples	443,250
Cold-Start Samples	240,064 (40.67%)
Warm Samples	350,191 (59.33%)

表 13：冷启动定义特征。若这六个历史活动特征中任一为零（析取准则），则样本被定义为冷启动。

特征名	粒度	窗口	描述
offer_net_ordered_gms_amt_sum_90d	Offer	90-day	商品总销售额（美元）
offer_net_ordered_gms_amt_sum_365d	Offer	365-day	商品总销售额（美元）
offer_net_shipped_units_sum_90d	Offer	90-day	发货件数
offer_net_shipped_units_sum_365d	Offer	365-day	发货件数
offer_asin_net_ord_gms_sum_90d	ASIN	90-day	ASIN 聚合 GMS（美元）
offer_asin_net_ship_units_sum_90d	ASIN	90-day	ASIN 聚合发货件数

表 14：半合成数据集统计。

数据集	样本数	处理 %	用途
Imbalanced Train	80,000	7.8%	DML/Mean Baseline
Balanced Train	20,839	30%	NCM
Test (All)	20,000	30%	All methods

表 15：半合成数据模式。每个样本包含观测结果、真实 CATE、真实倾向得分、两个潜在结果和 72 个 MinMax 缩放特征。

列名	描述
treatment	二元处理指示器（0/1）
y_observed	观测结果 = $T \times y1 + (1 - T) \times y0$
true_tau	真实 CATE = $y1 - y0$
propensity_score	真实 $P(T = 1 \mid X)$
y0_potential	控制条件下的反事实结果
y1_potential	处理条件下的反事实结果
feature_0…feature_71	72 个特征（0-1 缩放）

表 16：实验设计：各方法对应的训练与评估数据。

方法	训练数据	样本数	处理 %	测试数据
生产评估（表 3）				
NCM	Balanced Train (A)	1.53M	45.9%	Balanced Test (C)
ColdNet	Balanced Train (A)	1.53M	45.9%	Balanced Test (C)
Baseline DragonNet	Imbalanced Train (B)	9.59M	8.9%	Balanced Test (C)
半合成验证（表 1）				
Mean Baseline	Imbalanced Semi-Synth	80K	7.8%	Semi-Synth Test
DML (XGBoost)	Imbalanced Semi-Synth	80K	7.8%	Semi-Synth Test
NCM (DragonNet)	Balanced Semi-Synth	20.8K	30%	Semi-Synth Test